جامعة سيدي محمد بن عبدالله بفاس
ⵜⴰⵙⴷⴰⵡⵉⵜ ⵙⵉⴷⵉ ⵎⵓⵃⴰⵎⴻⴷ ⴱⵏ ⵄⴱⴷⵍⵍⴰⵀ ⴷⴼ ⴼⴰⵙ
UNIVERSITÉ SIDI MOHAMED BEN ABDELLAH DE FES
المدرسة العليا للتكنولوجيا
ⵜⵉⵎⵙⵙⵉⵔⵜ ⵜⴰⵏⴰⵡⴰⵢⵜ ⵏ ⵜⵉⴽⵏⵓⵍⵓⵊⵢⵜ
ECOLE SUPÉRIEURE DE TECHNOLOGIE

CAHIER DES CHARGES

Projet de Fin d'Études (PFE)

Exploitation des données de ventes d'une PME de restauration : Business Intelligence, analyse des paniers d'achat et prévision de la demande

Département Informatique

Filière : ID

Niveau : 2éme année

Réalisé par : **Hafsa GHOUZI** **et** **Douae AARABA**

Encadré par : **Mme L. BENNIS**

Année universitaire : 2026/2027

1. Contexte et problématique

Les petites et moyennes entreprises de restauration enregistrent chaque jour leurs ventes grâce à leur système de caisse, mais n'exploitent pas toujours pleinement ces données. Pourtant, savoir quels produits se vendent ensemble, à quels moments la demande est la plus forte ou comment elle évolue permet d'améliorer la gestion du menu, des stocks et des équipes.
Ce projet s'appuie sur un jeu de données réel et récent : les transactions d'une PME de restauration exploitant plusieurs points de vente en Indonésie, de janvier à septembre 2025. Il consiste à stocker ces données dans un environnement big data (Hadoop), à les organiser dans un entrepôt de données, à les analyser par des techniques de data mining et à construire des modèles de machine learning, au service d'un tableau de bord d'aide à la décision.

Problématique

Comment exploiter les données de ventes d'une PME de restauration pour comprendre les habitudes d'achat, recommander des produits associés et prévoir la demande ?

Questions de recherche

1- Quels produits, quelles heures et quels points de vente génèrent le plus de ventes ?
2- Quels produits sont le plus souvent achetés ensemble ?
3- Quel modèle prévoit le mieux la demande des prochaines semaines ?

2. Objectifs du projet

Objectif général

Concevoir et développer une solution d'aide à la décision pour une PME de restauration, combinant environnement big data, entrepôt de données, data mining, Business Intelligence et modèles de machine learning, à partir de données de ventes réelles.

Objectifs spécifiques

- Stocker les données brutes dans un environnement big data (HDFS).
- Construire avec Hive un entrepôt de données en schéma en étoile.
- Nettoyer et analyser les données avec Python (pandas).
- Identifier les produits fréquemment achetés ensemble (comptage des paires avec MapReduce, règles d'association) et regrouper les produits selon leur profil de vente (clustering).
- Construire un tableau de bord interactif Power BI.
- Prévoir la demande avec des modèles de machine learning, les comparer avec une méthode de référence simple, les évaluer et retenir le modèle final.
- Interpréter les résultats et formuler des recommandations utiles à la gestion de la PME (menu, horaires, produits à associer).
- Proposer une application web de recommandation de produits (Flask, HTML, CSS).

3. Présentation du jeu de données

Élément	Description
Titre	Anonymous Transactional Dataset
Source	Mendeley Data
Auteurs	Engel, M. M.; Gaol, F. L.; Kurniawan, A.; Budiharto, W.
Licence	CC BY 4.0
Nature	Données réelles de ventes d'une PME de restauration (plusieurs points de vente, Indonésie)
Période	Janvier à septembre 2025
Volume	53 820 transactions (un ticket par ligne), et 97 produits

4. Besoins du projet

4.1 Besoins fonctionnels

Réf.	Description
BF1	Copier les fichiers de transactions et de produits dans HDFS.
BF2	Créer avec HiveQL les tables et l'entrepôt de données : table de faits (tickets), dimensions (date, point de vente, paiement, produit) et table de liaison ticket-produit.
BF3	Extraire les données de Hive via Python (pandas), les nettoyer et créer de nouvelles variables (heure, jour, mois).
BF4	Réaliser une analyse exploratoire : ventes par produit, heure, jour et point de vente.
BF5	Extraction des règles d'association avec MapReduce (calcul du support et de la confiance).
BF6	Regrouper les produits en classes homogènes (clustering).
BF7	Conception d'un tableau de bord Power BI : chiffre d'affaires, produits les plus vendus, heures de pointe, comparaison des points de vente et analyse des paiements.
BF8	Prévision de la demande : entraînement, évaluation et sélection du meilleur modèle.
BF9	Développement d'une application web de recommandation de produits.

5. Démarche du projet

Le projet suit la chaîne de traitement suivante, de la donnée brute jusqu'à l'application finale

N°	Étape	Description
1	Données	Compréhension du jeu de données, exploration initiale, qualité.
2	Stockage (HDFS)	Copie des fichiers dans le système de fichiers distribué de Hadoop.
3	Entrepôt (Hive)	Création des tables et de l'entrepôt en étoile avec HiveQL ; requêtes de contrôle.
4	Extraction des données	Extraction des données depuis Hive via Python
5	Nettoyage et EDA	Traitement des erreurs et valeurs aberrantes, analyse exploratoire.
6	Data mining	Comptage des paires de produits (MapReduce), règles d'association, clustering.
7	Power BI	Tableau de bord interactif.
8	Machine learning	Entraînement de modèles de prévision de la demande.
9	Évaluation et choix	Mesure des performances sur période de test (MAE, RMSE) et sélection du modèle final.
10	Déploiement	Application web de recommandation de produits.

6. Architecture et outils proposés

Besoin	Outil envisagé
Dataset	Mendeley Data
Environnement	Hadoop
Stockage distribué	HDFS
Entrepôt de données	HiveQL, schéma en étoile
Traitement distribué	MapReduce (comptage des paires de produits)
Préparation, analyse et machine learning	Python (Pandas [préparation] , scikit-learn [clustering], mlxtend [règles d'association], statsmodels [prévision])
Tableau de bord	Power BI
Application	Flask, HTML, CSS